

# Report

0616329 李京叡

## Data Input:

用 panda 的 `read_csv` 讀取檔案

## Data Preprocessing:

1. 移除有 missing value(?)的欄位: 'workclass', 'occupation', 'native-country'，另外因為我覺得 education-level 和 education-num 所代表的資訊是重複的，因此也移除了'education-level'的欄位。
2. 打散所有 data
3. 將 data 以 7:3 分成 train 和 validation 兩組

## Model construction:

Decision tree:

5 個主要的 function: `tree_build`, `entropy`, `info_gain`, `remainder`, `find_threshold`，在 `build_tree` 時，會去找當下 information gain 最大的屬性來分割資料，計算 information gain 需要用到 `entropy`, `remainder`，此外若屬性是連續的，則會先用 `find_threshold` 找出最佳分割點，把 data 分成兩類，大於 `threshold` 和小於 `threshold`。

Random forest:

隨機從 data 中取 100 筆資料建 decision tree，總共建了 3 棵，驗證時把資料送進每一棵樹並取得結果，最多數的結果即為最後答案。

## Results (number of data=500):

Decision tree:

```
Predicted Positive Predicted Negative
Target Postive      3             32
Target Negative     4             111
Accuracy: 0.760000
Sensitivity: 0.085714
Precision: 0.428571
```

Confusion matrix:

	Predicted Positive	Predicted Negative

Target Postive	3	32
Target Negative	4	111

Accuracy: 0.76

Sensitivity: 0.085714

Precision: 0.428571

**Random forest:**

```

Target Postive      Predicted Positive Predicted Negative
Target Negative      0              33
Accuracy: 0.780000
Sensitivity: 0.000000
Precision: 0.000000

```

	Predicted Positive	Predicted Negative
Target Postive	0	33
Target Negative	0	117

Accuracy: 0.78

Sensitivity: 0

Precision: 0

## Kaggle Submission:

Overview	Data	Notebooks	Discussion	Leaderboard	Rules	Team	My Submissions	Submit Predictions
31	mick0713						0.80682	9 3d
32	Cheng-yi Lai						0.80477	4 2d
33	k6						0.80034	1 2d
34	AfrienTsai						0.78464	12 6h
35	YianTai						0.77713	1 3d
36	ALBERTOPERARO						0.76996	10 1h
37	toosyou.second						0.76518	1 23d
38	Ching-Jui,Lee						0.76518	3 17h
<b>Your Best Entry ↑</b> Your submission scored 0.74607, which is not an improvement of your best score. Keep trying!								
39	JeffLai						0.76518	1 2d
40	Petertsai1998						0.76040	11 2d
41	Howard Roark 4u4m						0.75563	1 2h
42	Mymi Sou						0.66348	1 6h
43	Sheng Rong						0.63003	4 2d
	📍 sample_submission.csv						0.52218	
44	StevenLi_04						0.34880	1 2d

上面顯示的最高成績，是預測結果全部皆為 0 的，因為我一開始程式有一些錯誤，導致預測結果皆為 0，但後來改好後的正確率又沒辦法超越，因此 0.74607 應該才是比較接近我的 model 的正確率。

## Comparison & Conclusion:

我覺得正確率沒辦法提高的原因是為 train 的 data 太少，但是因為算 threshold 非常花時間，要先把 data 排序，再算出連續兩個值的中點，再去算 information gain，我試過把所有 data 都餵進去，但是跑了好幾個小時，還是跑不出來，為了方便測試與得到結果，我只好把 data 量都縮小，因此正確率沒辦法提高。